

ОТЧЕТ КОМАНДЫ DOZEN

Введение

В работе решалась задача классификации рамановских спектров мозговой ткани по трем экспериментальным группам: **control**, **endo** и **exo**. Цель состояла в том, чтобы построить устойчивую и интерпретируемую модель, определяющую класс образца по спектру, а также выделить спектральные области, наиболее важные для различения групп.

Особый интерес представляли изменения, связанные с **HSP70**. В спектрах искался не отдельный уникальный пик белка, а различия в общем молекулярном профиле ткани. Дополнительно сравнивалась информативность двух диапазонов: около 1500 см^{-1} и около 2900 см^{-1} .




Рисунок 1 - Усредненные сырые рамановские спектры трех экспериментальных групп.

Описание данных и постановка задачи

Исходные данные были представлены в виде **трех архивов**, соответствующих классам **control**, **endo** и **exo**. В каждом архиве находилось по **4 папки** с образцами ткани. Внутри папок содержались текстовые файлы с колонками **X**, **Y**, **wave**, **intensity**. Один файл включал около **500 локальных спектров**, измеренных в разных точках образца.

Из названий файлов извлекалась метайнформация, наиболее важной из которой оказались:

- **region** — область мозга;
- **класс**;
- **спектральный диапазон** — около 1500 см^{-1} или 2900 см^{-1} .

Основные трудности были следующими:

- значения **wave** не совпадали между файлами и даже внутри одного файла;

- данные содержали два разных спектральных диапазона, несущих разную биохимическую информацию;
- часть признаков могла давать искусственно завышенные метрики.

Задача состояла в том, чтобы:

- привести сырые файлы к единому формату;
- согласовать спектральную сетку;
- выполнить предобработку;
- выделить признаки;
- обучить модель без утечки;
- определить значимые спектральные области.

Подготовка и предобработка данных

Каждый текстовый файл был распарсен так, чтобы для каждой пары координат (X, Y) восстанавливался отдельный спектр. Затем спектры переводились в табличную форму.

Так как значения **wave** немного различались, была выполнена **унификация спектральной оси**: близкие значения объединялись в общие столбцы с округлением до близкого шага. Это позволило сделать спектры сопоставимыми.

После этого были сформированы **два отдельных датасета**:

- для диапазона **1500 см⁻¹**;
- для диапазона **2900 см⁻¹**.

Попытка объединить оба диапазона в одну модель показала худшие результаты, поэтому дальнейший анализ проводился отдельно.

Для спектров применялись:

- **вычитание baseline**;
- **нормализация**;
- **сглаживание**;
- **производные**;
- расчет агрегированных признаков.

Эти шаги были нужны для удаления фонового сигнала, снижения влияния шума и приведения спектров к сопоставимому виду.




Рисунок 2 - Пример коррекции baseline для исходных рамановских спектров.




Рисунок 3 - Усредненные спектры трех групп после baseline correction, сглаживания и нормализации.

После предобработки различия между усредненными спектрами стали менее выраженными визуально, но результат стал более корректным с точки зрения физического смысла данных.

Формирование признаков и анализ спектров

В качестве признаков использовались:

- значения интенсивности на общей спектральной сетке;
- **region**;
- инженерные признаки:
 - интегралы по окнам,
 - средние значения,

- максимумы и минимумы,
- стандартные отклонения,
- отношения между окнами,
- признаки на основе производных.

Визуальный анализ показал, что:

- средние спектры трех классов различаются;
- различия распределены по нескольким участкам спектра, а не по одному пику;
- спектры заметно зависят от **region** даже внутри одного класса.

Это означало, что анатомическая область мозга является важным фактором и должна учитываться при классификации.




Рисунок 4 - Усредненные спектры внутри класса control с разделением по регионам мозга.




Рисунок 5 - Сравнение спектров разных классов внутри отдела *cerebellum_left*.

Отдельной проблемой стала **утечка признаков**. При добавлении координат **X**, **Y** baseline-модель показывала почти идеальное качество. Однако выяснилось, что модель запоминала расположение точек измерения, а не реальные различия между классами. После удаления **X**, **Y** метрики снизились, но результат стал корректным.

Построение моделей и результаты

После исключения утечки были протестированы:

- **HistGradientBoostingClassifier**;
- **CatBoost**;
- **XGBoost**;
- нейросетевая модель.

Лучший результат показал **HistGradientBoostingClassifier**.

Для диапазона **1500 cm^{-1}** лучшая модель дала:

- **Accuracy = 0.838**
- **F1-macro = 0.836**

По классам:

- **control** — F1 около **0.83**;
- **endo** — F1 около **0.81**;
- **exo** — F1 около **0.87**.

Для диапазона **2900 cm^{-1}** результат оказался ниже:

- Accuracy = 0.781
- F1-macro = 0.778

Таким образом, диапазон 1500 см^{-1} оказался более информативным.




Рисунок 7 - Наиболее значимые признаки по permutation importance для лучшей модели.




Рисунок 8 - Матрица ошибок лучшей модели для диапазона 1500 см^{-1} .

Основные выводы по спектрам и областям

Наиболее важный результат состоит в том, что **главная диагностическая информация содержится в области около 1500 см^{-1}** . Именно этот диапазон дал лучшую классификацию и оказался наиболее полезным для различения классов **control**, **endo** и **exo**.

Диапазон 2900 см^{-1} тоже содержит полезную информацию, но его оказалось недостаточно для столь же уверенного разделения. Это значит, что различия между классами проявляются не только в липидно-белковом фоне, но и в более сложной структуре fingerprint-области.

По permutation importance наиболее значимыми оказались:

- **region**;
- окна около $990\text{--}1010\text{ см}^{-1}$;
- $1230\text{--}1310\text{ см}^{-1}$;
- $1430\text{--}1470\text{ см}^{-1}$;
- $1620\text{--}1700\text{ см}^{-1}$.

Это показывает, что различия между группами носят **многокомпонентный характер** и не сводятся к одному локальному пику. Особенно важной выглядит область **1620–1700 см⁻¹**, связанная с белковыми и амидными компонентами. Для задачи, связанной с HSP70, это выглядит содержательно правдоподобно: различия, вероятно, проявляются через изменение общего белкового профиля ткани.

Важность признака **region** показывает, что анатомическая область мозга существенно влияет на вид спектра. Следовательно, при анализе таких данных необходимо учитывать не только класс, но и локализацию измерения.

Также видно, что класс **exo** отделяется лучше остальных, тогда как **control** и **endo** частично перекрываются. Это может означать, что спектральные изменения при экзогенной экспрессии выражены сильнее и стабильнее.

Заключение

В ходе работы был построен полный pipeline анализа рамановских спектров: от парсинга исходных текстовых файлов до обучения интерпретируемой модели и анализа значимости признаков.

Основные трудности состояли в:

- несогласованности спектральной сетки;
- наличии двух разных диапазонов;
- необходимости предобработки спектров;
- обнаружении и устранении утечки по координатам **X, Y**.

В итоге было показано, что:

- спектры действительно позволяют различать классы **control**, **endo** и **exo**;
- наиболее информативным является диапазон **1500 см⁻¹**;
- важную роль играют **region** и несколько локальных спектральных окон;
- различия между группами распределены по нескольким областям спектра и связаны с изменением общего молекулярного профиля ткани.